

Noções Básicas sobre Alucinações em IA

Objetivos

Após concluir esta leitura, você será capaz de:

- Definir alucinações de IA.
- Listar os problemas causados pelas alucinações de IA e as formas de preveni-las.

Tempo estimado de leitura: 10 minutos

Introdução

Você pode utilizar modelos de linguagem de grande porte (LLMs) para gerar textos autoritativos em diversos domínios. No entanto, eles podem gerar informações que parecem corretas, mas são imprecisas. Eles também podem produzir conteúdo tendencioso. Esses problemas podem ser resultado de alucinações de IA. Nesta leitura, você aprenderá sobre alucinações de IA.

Alucinações de IA

Nas alucinações de IA, o modelo gera uma saída que apresenta como precisa, mas é vista como irrealista, imprecisa, irrelevante ou sem sentido pelos humanos. É semelhante à maneira como os humanos experienciam alucinações.

Por exemplo, houve um incidente em que o ChatGPT afirmou falsamente que um prefeito na Austrália foi considerado culpado e preso em um caso de suborno. Na realidade, o prefeito notificou as autoridades sobre um problema de suborno. (Referência: [Australian mayor readies world's first defamation lawsuit over ChatGPT content | Reuters](#))

O exemplo mostra que pode haver uma implicação significativa das alucinações de IA. No entanto, note que tais incidentes são raros e isolados.

As alucinações de IA estão fortemente associadas aos LLMs. Fatores como preconceitos nos dados de treinamento, treinamento limitado, complexidade do modelo e falta de supervisão humana podem causar alucinações de IA. Além disso, as saídas geradas pelos modelos de IA podem não ser baseadas nos padrões que os modelos aprenderam a partir dos dados de treinamento.

Problemas causados por alucinações de IA

Alucinações de IA podem ter implicações sérias. Por exemplo, se um LLM resumir incorretamente páginas de um documento legal, isso pode levar a disputas legais e litígios.

Alguns dos problemas causados são:

- Geração de informações imprecisas
- Criação de visões tendenciosas ou informações enganosas
- Entrada errada fornecida a aplicações sensíveis, como aquelas usadas em veículos autônomos ou no domínio médico

Métodos para mitigar alucinações

- Eliminando qualquer viés nos dados de treinamento e realizando um extenso treinamento dos modelos em dados de alta qualidade
- Evitando a manipulação das entradas que são fornecidas aos modelos
- Avaliação e melhoria contínuas dos modelos
- Ajustando um LLM pré-treinado em dados específicos do domínio

Prevenindo os problemas causados por alucinações de IA

É inevitável que alucinações ocorram dentro dos LLMs. O que pode ser frustrante é que o texto gerado muitas vezes contém erros sutis que são desafiadores de identificar. Existem algumas melhores práticas que você pode seguir. Estas incluem:

- Estar vigilante e entender que esses modelos não compreendem o significado real das palavras, mas estão focados em prever a próxima palavra em uma sequência com base em padrões. Esses modelos são treinados em grandes

quantidades de dados e aprendem padrões estatísticos, mas carecem de compreensão semântica ou entendimento **como os seres humanos**.

- Garantir supervisão humana regularmente para verificação de fatos e testes contínuos.
- Fornecer contexto adicional no prompt ou entrada. Isso permitirá que os LLMs compreendam melhor a saída desejada e gerem respostas mais precisas e contextualmente relevantes.

Resumo

Nesta leitura, você aprendeu que:

- Alucinações de IA referem-se a um modelo de IA gerando saídas apresentadas como precisas, mas vistas como irreais, imprecisas, irrelevantes ou sem sentido pelos humanos.
- A alucinação de IA pode resultar na geração de informações imprecisas, na criação de visões tendenciosas e na entrada errada fornecida a aplicações sensíveis.
- Você pode prevenir os problemas causados por alucinações de IA através de:
 - Treinamento extensivo com dados de alta qualidade,
 - Evitar manipulação,
 - Avaliação e melhoria contínuas dos modelos,
 - Ajuste fino em dados específicos do domínio,
 - Estar vigilante,
 - Garantir supervisão humana, e
 - Fornecer contexto adicional no prompt.

Registro de Mudanças

Data	Versão	Alterado por	Descrição da Mudança
29-01-2024	0.1	Santosh Kumar Sahu	Versão inicial criada

—>

